

Instituto Tecnológico y de Estudios Superiores de Monterrey

Operaciones de aprendizaje automático

Actividad - Código de experimentación base con MLFlow

Oscar Ulises López Vázquez

A01840039

Docente: Dr. Iván Reyes Amezcua

10 de Octubre del 2026

Experimentación con MLflow

Repositorio: https://github.com/oscarlv/tc5061/tree/main/week4

Implementación y ejecución

En esta actividad transfería la lógica del modelo Extra Trees elegido en la semana 3 a un nuevo script llamado train.py. En este script separé la carga de datos, la preparación, el entrenamiento y la evaluación en diferentes funciones. De igual manera realicé una copia limpia del notebook removiendo las imágenes y otras cosas que se solicitaron en la semana anterior y el nuevo notebook quedó solamente para explorar los datos. Al igual que con el notebook original mantuve como referencia de calidad alta cuando la calificación del vino es de 7 o más.

En general eliminé las filas duplicadas antes de dividir los datos. Conservé 4,256 observaciones para entrenamiento y 1,064 para prueba. Usé la semilla 42 en la partición (al igual que en el notebook), en los cinco grupos de validación y en el modelo.

Desde la carpeta **week4**, los comandos de instalación y ejecución son:

```
python3 -m venv .venv
source .venv/bin/activate
python -m pip install -r requirements.txt
python train.py
```

El script permite cambiar el número de árboles, las variables consideradas por división, las muestras mínimas por hoja, la profundidad y por supuesto la semilla. Por ejemplo:

```
python train.py --run-name 03_arboles_500 --n-estimators 500
```

En mi caso decidí comparar seis configuraciones y repetí la primera. MLflow guardó los parámetros, las cinco métricas, las predicciones, una matriz de confusión y el modelo en el experimento ***TC5061_Semana4_ExtraTrees***. Todos los comandos necesarios para poder replicar la experimentación están en el archivo README.

Para abrir la interfaz podemos utilizar el siguiente comando:

```
mlflow ui --backend-store-uri sqlite:///.mlflow/week4.db --host 127.0.0.1 --port 5004
```

Una vez que la interfaz está abierta podemos abrir http://127.0.0.1:5004, y deberían estar disponibles las siete corridas además de poder compararse.

Análisis de resultados

Como ya mencioné antes en esta actividad mantuve la configuración utilizada la semana pasada la cual consta de 500 árboles, max_features=sqrt, hoja mínima de 2 y profundidad sin límite la cuál por cierto obtuvo el mayor ROC-AUC de validación con un valor de 0.852581. La configuración inicial, con 300 árboles, obtuvo 0.852506. La diferencia en realidad fue muy pequeña, de apenas 0.000075, mucho menor que la variación entre los cinco grupos de validación (con una desviación de 0.010094). Por esta razón, no considero que aumentar los árboles haya dado una mejora clara. En las pruebas, el modelo de 500 árboles obtuvo ROC-AUC de 0.869886 y F1 de 0.416667.

Entre los valores probados, ***max_features*** fue el parámetro que más cambió el ROC-AUC de validación. Al usar 0.7 como valor en lugar de sqrt, nuestro resultado bajó a 0.847894. También encontré curioso que limitar la profundidad a 16 también redujo el resultado a 0.848566. Cambiar el número de árboles o las muestras mínimas por hoja tuvo un efecto menor.

Por otra parte la configuración con ***max_features***=0.7 obtuvo el mayor F1 de prueba, 0.470968. Sin embargo, elegí la configuración por validación y mantuve esta prueba como evaluación final. El motivo detrás de esta elección fue la métrica, en mi opinión personal me parece que mejorar el orden de las probabilidades no siempre mejora la detección con un umbral fijo.

La primera corrida y su repetición produjeron las mismas métricas y predicciones. Como limitaciones, usé una sola partición y pocos valores por parámetro. Además sólo 202 de las 1,064 muestras de prueba son de calidad alta. El recall de 0.297030 del modelo elegido muestra que todavía se dejan pasar muchos casos positivos. Pienso que mantener 300 árboles también podría ser razonable porque la diferencia de validación es mínima.

Los resultados explicados anteriormente corresponden únicamente a las corridas del script simplificado.

Evidencias de MLflow

Las capturas añadidas a continuación muestran las corridas nuevas. Los resultados completos se encuentran en **results/comparacion.csv**.

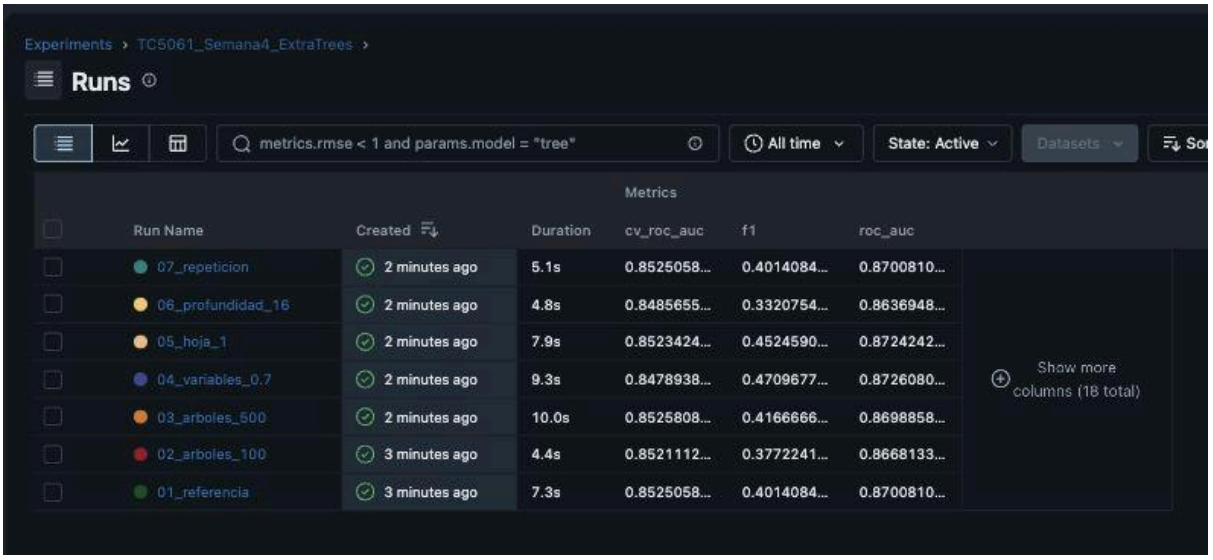


Figura 1. Comparación de métricas de las siete corridas.

Retomé el modelo elegido en el notebook y ejecuté seis configuraciones con la misma partición y semilla. La tabla nos permite comparar sus métricas. En mi caso en específico la corrida número 7 repite la referencia y me confirmó los mismos resultados.

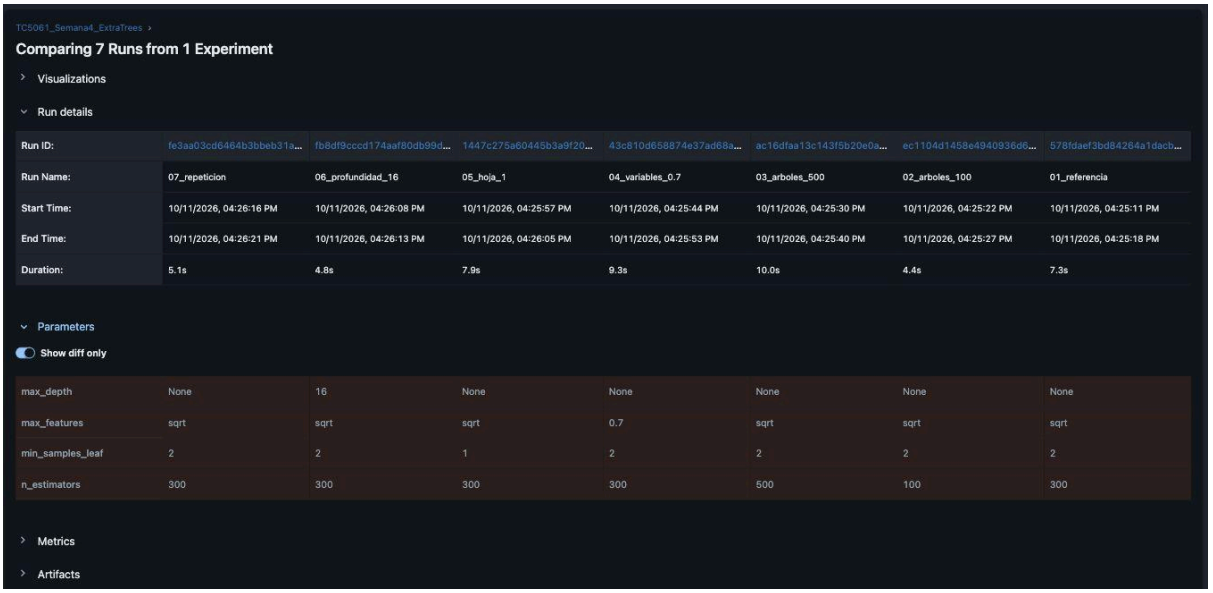


Figura 2. Comparación de los parámetros en la vista Compare.

Aquí podemos apreciar cómo para este experimento usé como referencia los valores del notebook: 300 árboles, sqrt y hoja mínima de 2. Además de esto cambié un parámetro por cada una de las corridas. Esta imagen nos permite ver qué opción probé en cada uno de los experimentos y al mismo tiempo poder relacionar cada ejecución con sus resultados.

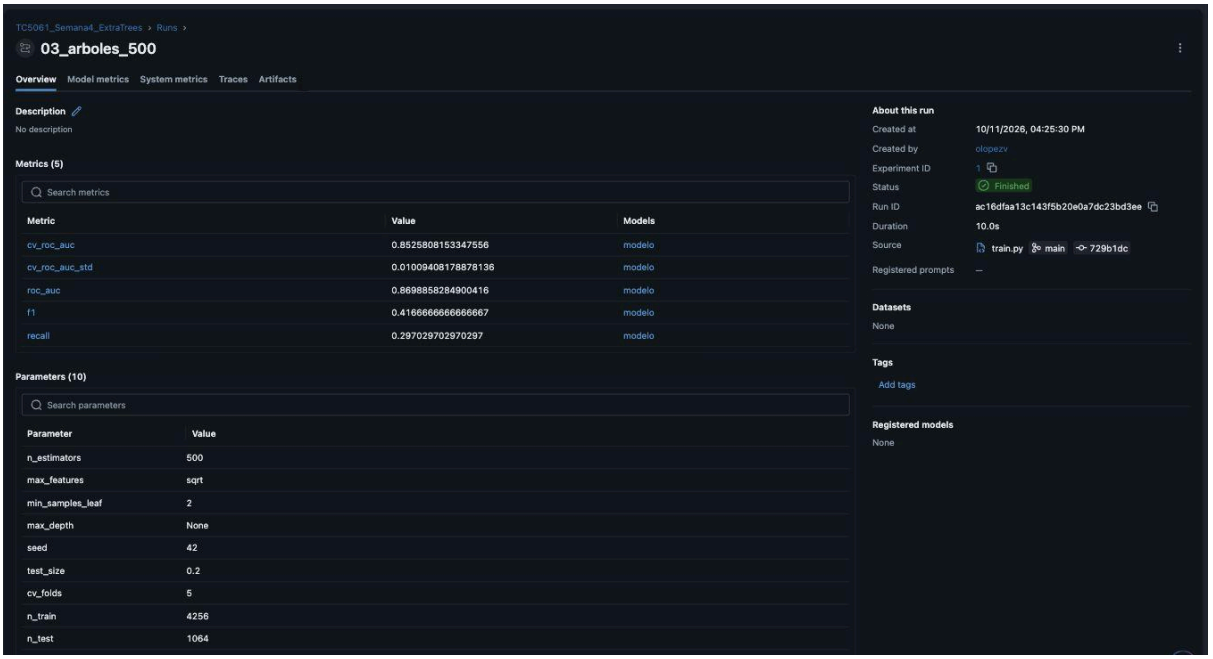


Figura 3. Detalle de la configuración con 500 árboles.

En esta imagen podemos apreciar detalles específicos de la 3ra ejecución con 500 árboles para poder revisar sus parámetros y métricas a detalle, esto lo hice para poder evaluar de la misma manera como lo hice en el notebook. Como podemos observar este experimento en específico obtuvo un valor para ROC-AUC (test) de 0.869886 y F1 de 0.416667. MLflow conserva estos resultados junto al modelo.

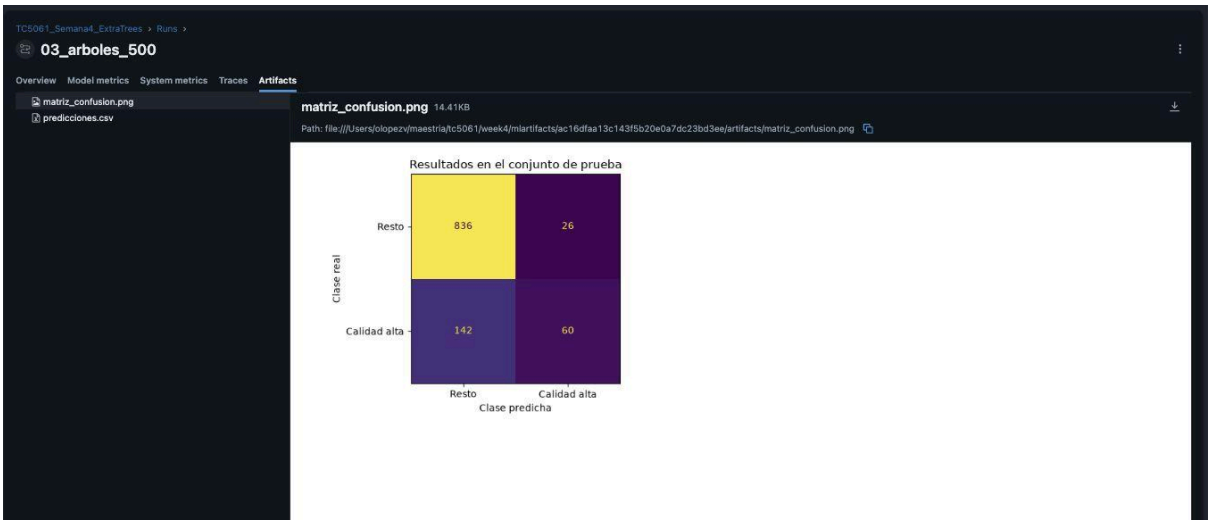


Figura 4. Artefactos guardados y matriz de confusión.

En esta imagen se puede observar cómo guardé la matriz de confusión al igual que en el notebook pero ahora en esta ocasión como un artefacto de MLflow. En esta ejecución

nuestro experimento pudo detectar 60 vinos de calidad alta y dejó pasar 142. Esto nos muestra que en esta ejecución el modelo todavía detecta pocos positivos.

Bibliografía

Huyen, C. (2022). *Designing machine learning systems: An iterative process for production-ready applications*. O'Reilly Media.

Lauchande, N. (2021). *Machine learning engineering with MLflow*. Packt Publishing.

MLflow. (n.d.). *MLflow tracking*. https://mlflow.org/docs/latest/ml/tracking/

Wilson, B. (2022). *Machine learning engineering in action*. Manning Publications.